

# Università degli Studi di Salerno

Dipartimento di Informatica



Progetto di Fondamenti di visione artificiale e biometria

Gruppo 12

**Professore**

Michele Nappi

**Tutor**

Dott.ssa Chiara Pero

**Studenti**

De Martino Angela

Spagna Zito Marika

## Sommario

Abstract .....	3
1. Introduzione.....	4
2. Stato dell'arte (lavori correlati) .....	6
3. Materiali e metodi .....	8
3.1 Dataset .....	8
3.2 Pre-processing.....	11
3.3 Riduzione della dimensionalità con PCA .....	12
3.4 Estrazione delle caratteristiche .....	13
3.5 Protocolli.....	14
3.6 Fusione con i movimenti oculari .....	16
3.7 Classificazione .....	17
4. Tecnologie utilizzate .....	18
5. Risultati .....	19
6. Conclusione e sviluppi futuri .....	24
Bibliografia.....	25
Dizionario .....	27

## Abstract

Lo scopo di questa ricerca è quello di identificare le emozioni utilizzando i segnali EEG attraverso un approccio basato sull'analisi dei dati grezzi. Il riconoscimento delle emozioni dal segnale EEG richiede l'estrazione di caratteristiche significative dei segnali e la successiva classificazione delle emozioni. L'estrazione di caratteristiche ottimali da segnali EEG a canale multiplo è un problema impegnativo a causa dei rumori e degli artefatti presenti nel segnale. Pertanto, è importante eseguire una fase preliminare di pre-processing per preparare i dati eliminando informazioni ridondanti o inconsistenti.

L'articolo presenta un'analisi dello stato dell'arte e dei lavori correlati, seguita da una descrizione dettagliata della metodologia utilizzata. L'analisi è stata eseguita su un set di dati specifico chiamato **SEED-IV**.

Questo studio ha seguito diversi step che includono pre-processing dei dati, estrazione delle caratteristiche, riduzione della dimensionalità e addestramento dei modelli. Più precisamente le caratteristiche estratte sono state utilizzate per addestrare modelli di machine learning come SVM, Random Forest, XGBoost, Logistic Regression, Naive Bayes e Adaboost per la classificazione delle emozioni.

Sono state considerate anche le informazioni sui movimenti oculari, in quanto correlati alle emozioni umane. I risultati ottenuti sono presentati e discussi insieme alle considerazioni sull'interpretazione dei risultati.

I risultati ottenuti da questo studio possono contribuire allo sviluppo di metodi di individuazione delle emozioni basati su segnali EEG, migliorando la comprensione delle connessioni tra l'attività cerebrale e le emozioni umane.

## 1. Introduzione

Le **emozioni** possono essere definite come gli stati psicologici del sentire i quali si intrecciano attraverso circostanze, temperamento, relazioni, motivazioni, disposizioni, etc. Poiché le emozioni hanno una forte correlazione con l'attività mentale, possono essere innescate da alcuni stimoli esterni come film, immagini, scenari, suoni o alcuni approcci interni come memorizzare ricordi interessanti, emotivi, tristi ed ispiranti.

Sempre più spesso la comunità scientifica si sta interessando alla comprensione dell'interazione tra le emozioni umane e i dispositivi elettronici tramite un'adeguata interfaccia neurale chiamata BCI (Brain-Computer Interface) al fine di sfruttarne il potenziale ed avanzare nella neuroscienza e sviluppare nuove applicazioni terapeutiche.

Per sviluppare un sistema BCI sicuro, il riconoscimento delle emozioni svolge un ruolo vitale.

Un possibile utilizzo della tecnologia potrebbe essere l'implementazione di un sistema di sicurezza che considera le emozioni incontrollate dell'utente. Ad esempio, si potrebbe applicare tale sistema a un bancomat in modo che non eroghi denaro se l'utente manifesta segnali di paura, come reazione a una potenziale rapina. [1] Inoltre, il processo di riconoscimento delle emozioni ha un controllo efficace sui dispositivi come il computer e le applicazioni assistive [2]. Oltre a ciò, il riconoscimento delle emozioni ha altre applicazioni come la terapia musicale [3,4], la guida sicura [5,6], l'intelligenza artificiale [7], etc.

Poiché tutti i tipi di cambiamenti psicofisiologici influenzano le attività del cervello, l'elettroencefalogramma (**EEG**) potrebbe essere un possibile modo per leggere l'emozione umana dal segnale neuroelettrico.

Gli EEG rappresentano una registrazione delle attività elettriche del cervello, acquisite mediante l'uso di elettrodi posizionati sulla superficie del cuoio capelluto. Tali elettrodi rilevano l'attività elettrica dei neuroni cerebrali e registrano le variazioni di tensione generate dalla loro attività.

La biometria cognitiva ha adottato i segnali EEG, descritti per la prima volta nel 1875 da Richard Canton [8], per analizzare l'attività cerebrale e comprendere la funzionalità del cervello. La biometria cognitiva è quindi diventata una tecnologia emergente per l'analisi dei segnali EEG e la valutazione delle funzioni cerebrali in diversi contesti, offrendo opportunità di rilevare disturbi cognitivi e ottenere informazioni sullo stato mentale dei soggetti analizzati.

La registrazione dei segnali EEG è però un procedimento complesso che richiede grande attenzione e precisione. Durante l'acquisizione di questi segnali diversi fattori devono essere presi in considerazione per garantire la corretta registrazione e l'affidabilità dei risultati. Le tecniche di sensing, ad esempio, giocano un ruolo cruciale: è fondamentale utilizzare elettrodi di alta qualità e garantire un buon contatto con la cute del cuoio capelluto per ottenere segnali chiari e stabili. Inoltre, la posizione degli elettrodi deve seguire gli standard internazionali, come il sistema 10-20[2], per garantire la ripetibilità delle prove.

L'origine del segnale elettroencefalografico deve essere compresa per identificare e distinguere le attività cerebrali di interesse. Inoltre, il protocollo di stimolazione, se presente, deve essere attentamente pianificato e implementato. Tutti questi aspetti richiedono una pianificazione accurata, competenza tecnica e attenzione ai dettagli per ottenere dati di alta qualità e risultati affidabili.

Attualmente, esistono diverse tecniche per il riconoscimento delle emozioni, tra cui l'analisi dei segnali EEG, il tracciamento dei movimenti oculari e il riconoscimento delle espressioni facciali. Tuttavia, il metodo basato sul riconoscimento delle espressioni facciali ha dimostrato di essere particolarmente limitato, in quanto le espressioni possono essere facilmente influenzate e non rappresentare necessariamente l'emozione reale della persona.

Per riconoscere l'emozione dal segnale EEG, sono necessarie due parti principali:

I) L'estrazione di caratteristiche significative dai segnali EEG emotivi

II) la classificazione delle emozioni.

Avendo un certo numero di rumori e artefatti nel segnale EEG, l'estrazione delle caratteristiche ottimali dai segnali EEG a canale multiplo è un problema impegnativo. Per affrontare in modo efficace il problema della classificazione delle emozioni, è fondamentale esaminare attentamente i dati di input e valutare se sia opportuno applicare una fase preliminare di pre-processing. Questo processo mira a preparare i dati eliminando informazioni ridondanti o inconsistenti e utilizzando solo quelle essenziali per l'analisi, al fine di ottimizzare l'efficienza computazionale.

Esistono diverse tecniche di pre-processing disponibili, la scelta delle quali dipende principalmente dal dominio di riferimento e dal tipo di segnale da trattare.

Questo lavoro mira ad analizzare le tecniche di estrazione delle caratteristiche e di pre-processing più diffuse in letteratura. Da esse si è poi passati ad un'analisi dei modelli e delle tecniche di *Machine learning* più adatte al riconoscimento delle emozioni a partire dai segnali EEG. In un secondo momento sono stati considerati anche i movimenti oculari, in quanto questi ultimi sono strettamente collegati all'attività cerebrale coinvolta nell'elaborazione delle emozioni. Ad esempio, le variazioni nella fissazione o dilatazione delle pupille possono essere indicatori importanti degli stati emotivi. Considerare i movimenti oculari insieme agli EEG permette di considerare i cambiamenti fisiologici e le risposte emotive correlate, fornendo così un quadro più completo delle emozioni. Questa combinazione può anche migliorare l'accuratezza nella classificazione di emozioni rispetto all'utilizzo separato di ciascun segnale.

Sono state portate avanti tre fasi principali nel processo di sviluppo. Una prima fase di pre-processing dei dati, dove sono state incluse tecniche di preparazione dei segnali quali filtro passa-banda, filtro Notch etc... A seguire una fase di estrazione delle caratteristiche e di riduzione della dimensionalità con PCA. Infine, per la fase finale ci si è concentrati sull'addestramento di modelli, precisamente dei modelli *SVM*, *Random Forest*, *XGBoost*, *Logistic Regression*, *Naive Bayes* e *Adaboost*.

La classificazione è stata eseguita considerando 3 approcci: dipendente dal soggetto, indipendente dal soggetto e basato sul soggetto per osservare l'accuratezza di classificazione dei modelli proposti.

Il metodo proposto è stato applicato al set di dati *SEED-IV (Stress and Emotion in Everyday Decision-making - Interactive Version)*.

L'articolo segue una struttura ben definita. Nel paragrafo 2 "*Stato dell'arte*" viene condotta un'analisi approfondita dello stato dell'arte e dei lavori correlati, mettendo in luce le soluzioni proposte da altri ricercatori e le limitazioni dei progetti esaminati. Successivamente, nel paragrafo 3, nella sezione "*Materiali e metodi*", viene illustrata la metodologia utilizzata: prima di tutto vengono fornite informazioni dettagliate sul dataset utilizzato e come abbiamo organizzato i dati. A seguire vengono elencate le tecniche di pre-processing, di estrazione delle caratteristiche e i modelli utilizzati, per l'analisi dei segnali. Inoltre, vi è anche un paragrafo in cui vengono specificati i vari protocolli di suddivisione dei dati. Il paragrafo 4 "*Tecnologie utilizzate*" delinea le tecnologie impiegate nello studio e nel paragrafo 5 "*Risultati*" vengono presentati i risultati ottenuti. Successivamente, nel paragrafo conclusivo "*Conclusione e sviluppi futuri*", vengono fornite le considerazioni sul significato e l'interpretazione dei risultati ottenuti.

## 2. Stato dell'arte (lavori correlati)

Negli ultimi anni, si è riscontrato un crescente interesse nello studio dei segnali EEG, poiché è stato riconosciuto il loro potenziale nel fornire informazioni di valore: sono stati sviluppati e valutati vari prototipi di sistemi indossabili all'avanguardia per il riconoscimento delle emozioni, che consentono la percezione e il feedback emotivo.

L'analisi delle espressioni facciali rappresenta una delle modalità più popolari per il riconoscimento emotivo. Ekman e Friesen [30] hanno introdotto il concetto di "emozioni di base", tra cui paura, ira, sorpresa, disgusto, gioia e tristezza, dopo aver studiato le espressioni facciali di diverse culture. Questa scoperta ha stimolato numerosi approcci nel campo del riconoscimento emotivo basati sull'analisi facciale negli ultimi decenni [31], [32].

Nonostante l'analisi tradizionale delle espressioni facciali sia stata predominante nel riconoscimento emotivo, c'è un crescente interesse verso altre modalità come il tatto e l'EEG. L'analisi dei segnali EEG ha guadagnato popolarità negli ultimi anni grazie al suo potenziale nel fornire informazioni rilevanti per il riconoscimento delle emozioni e per applicazioni come l'autenticazione.

Un esempio di integrazione di diverse modalità è stato condotto da Tsalamal et al. [33], in cui sono state combinate l'analisi delle espressioni facciali e la stimolazione tattile per valutare la valenza emotiva. Questo approccio multidimensionale può contribuire a migliorare la precisione e l'affidabilità dei sistemi di riconoscimento emotivo. Tuttavia, l'analisi dei segnali EEG presenta notevoli sfide a causa della loro complessità intrinseca, pertanto sono stati condotti numerosi studi per affrontare la processazione dei dati EEG al fine di ottenere informazioni significative e affidabili.

Come precedentemente accennato, uno dei principali problemi risiede nella presenza di rumore e interferenze indesiderate. Per mitigare questo problema, nella letteratura sono stati proposti diversi metodi di pre-processing. Questi metodi includono tecniche di rimozione del rumore, come il filtraggio spaziale e temporale, che consentono di isolare i segnali di interesse dagli artefatti indesiderati.

Più nello specifico le tecniche più comuni di pre-processing applicate ai segnali EEG nel contesto della biometria cognitiva [9] sono filtraggio, rimozione del rumore, rimozione di artefatti, segmentazione, ricampionamento, normalizzazione.

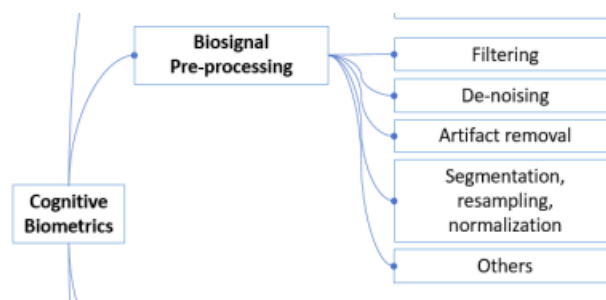


fig.1 Principali tecniche di pre-processing per i segnali EEG (Sensors p.3)

Queste tecniche sono estremamente importanti perché consentono di rimuovere componenti indesiderate, eliminare distorsioni, rimuovere anomalie, individuare pattern specifici, adattare i dati e rendere i dati comparabili. Una volta individuate le tecniche di pre-elaborazione adatte al dominio di riferimento si passa alla feature extraction.

L'estrazione delle caratteristiche è anch'esso un aspetto cruciale nell'analisi dei segnali EEG perché permette d'identificare informazioni rilevanti e discriminare tra le classi di segnali e ridurre il rumore.

La letteratura scientifica riporta vari metodi di ricerca utilizzati per identificare le caratteristiche rilevanti all'interno dei segnali. Tra questi, spiccano l'Analisi delle Componenti Indipendenti (ICA), l'Adaptive Weighted ICA (AWICA) e la Trasformata di Fourier a breve tempo (STFT).

In [12] ad esempio viene affermato che nello studio dei segnali EEG, per la rilevazione efficiente dell'epilessia, vengono estratte le caratteristiche dal segnale utilizzando la Trasformata di Wavelet Discreta (DWT); le caratteristiche in questione includono entropia, minimo, massimo, media, mediana, deviazione standard, varianza e tanto altro. A seguito di questo viene applicata la decomposizione modale empirica (EMD) al fine di scomporre il segnale EEG in diverse funzioni modali intrinseche (IMFs). Una volta ottenute le IMFs sono state raggruppate secondo il metodo PHA ed è stata calcolata la distanza di Kolmogorov.

Viene, sempre in questo articolo scientifico, affermato che per l'estrazione delle caratteristiche il metodo migliore è la CPS perchè permette di massimizzare la varianza dei segnali EEG filtrati in banda passante per una classe e limita le fluttuazioni della classe opposta.

In [1] viene detto che le caratteristiche selezionate dovrebbero rappresentare il segnale e discriminarlo il più possibile. Più nello specifico in questo documento si fa riferimento a [26] e [27]. Nel primo riferimento si parla della tecnica CWT (Continuous Wavelet Transform) come nuovo mezzo per estrarre le caratteristiche mentre nel secondo si propone la PCA per il trattamento di dati continui ed una sua variazione chiamata permutational principal components per gestire altre tipologie in maniera efficiente.

In [28] viene affermato che i metodi di estrazione delle caratteristiche vengono applicati per ridurre la complessità e la dimensionalità dei dati ingresso ai modelli d'apprendimento. Le caratteristiche vengono comunemente estratte sulle bande di frequenza delta, theta, alpha, beta e gamma. In letteratura alcuni dei metodi di estrazione delle caratteristiche disponibili sono la misura di asimmetria, la densità spettrale di potenza (PSD), l'entropia differenziale (DE), la Trasformata di Wavelet, l'asimmetria differenziale (DASM), l'asimmetria relativa (RASM) e caudalità differenziale (DCAU).

In [29] l'estrazione delle caratteristiche è basata su EMD (Entropia Campionaria). L'EMD viene prima applicata nell'estrazione delle caratteristiche per decomporre i segnali EEG in una serie di IMF (funzioni di modalità intrinseca). Successivamente, vengono calcolate le entropie campionarie delle IMF per costruire vettori di caratteristiche.

Dato che le emozioni presentano molteplici indicatori sia all'interno che all'esterno del nostro corpo, sono state sviluppate diverse modalità per costruire modelli di riconoscimento delle emozioni. Queste modalità includono l'analisi delle espressioni facciali, delle voci e dei gesti. Tuttavia, l'utilizzo di elettrodi per rilevare l'attività cerebrale può essere costoso in termini di tempo e può introdurre rumore e artefatti nei sistemi, compromettendo le prestazioni complessive. La comunità di Interazione Uomo-Computer (HCI) richiede configurazioni convenienti e facili da usare per le interazioni cervello-computer emotive. Negli ultimi anni, le reti neurali profonde hanno raggiunto prestazioni di alto livello in diversi campi di ricerca. Alcuni ricercatori hanno introdotto reti neurali profonde nell'elaborazione dell'EEG e i loro risultati sperimentali hanno dimostrato la superiorità di tali reti rispetto ai metodi convenzionali superficiali.

Per sfruttare i vantaggi delle diverse modalità di riconoscimento delle emozioni, sono state proposte diverse architetture multimodali profonde. Ad esempio, Ngiam et al. hanno proposto l'apprendimento multimodale profondo per creare rappresentazioni condivise efficaci tra modalità diverse, come audio e video. Recentemente, Tzirakis et al. hanno proposto il riconoscimento delle emozioni multimodale end-to-end utilizzando informazioni uditive e visive. Hanno utilizzato una combinazione di reti neurali convoluzionali e reti neurali residue per elaborare rispettivamente i dati uditivi e visivi. Le uscite delle due reti sono state concatenate e utilizzate come input per un LSTM (Long Short-Term Memory) a due strati per catturare le informazioni contestuali.

### 3. Materiali e metodi

#### 3.1 Dataset

Per l'analisi dei segnali EEG, sono disponibili diversi dataset pubblici altamente rappresentativi, che offrono un mezzo per confrontare le tecniche di elaborazione dei segnali. Alcuni di questi dataset includono biosegnali provenienti dallo stesso individuo, ma registrati in diversi momenti nel tempo, il che risulta particolarmente utile per valutare l'affidabilità delle tecniche di biometria cognitiva anche in contesti diversi e identificare eventuali errori nell'acquisizione dei dati. Tra i dataset più importanti si trovano il *SEED-IV* (Stress and Emotion in Everyday Decision-making - Interactive Version), il *BED* (Biometric EEG dataset), il *DEAP* (a dataset for emotion analysis using EEG, physiological and video signals) e il *BCI2008 GrazB* (Brain-Computer Interface 2008 Graz Brain-Computer Interface Competition) [3].

Nel nostro progetto abbiamo utilizzato il dataset **SEED-IV**, parte del The SJTU Emotion EEG Dataset (SEED), per individuare e riconoscere emozioni. In questo dataset sono stati scelti con cura settantadue filmati da uno studio preliminare, che tendeva a indurre **felicità, tristezza, paura o emozioni neutre**.

Il dataset è organizzato in sessioni, prove e soggetti partecipanti, comprende un totale di **15 soggetti**, ciascuno dei quali ha svolto tre sessioni separate, corrispondenti a diversi giorni di prove. Ogni sessione contiene **24 prove**, che rappresentano le diverse visualizzazioni dei video.

Durante ogni prova, i segnali EEG sono stati registrati utilizzando il sistema *NeuroScan ESI*, che dispone di **62 canali** di misurazione. Inoltre, i dati relativi ai movimenti oculari sono stati raccolti utilizzando gli occhiali per il tracciamento oculare *SMI*. Un diagramma del programma del processo è il seguente.




fig.2 Protocollo degli esperimenti sull'emozione progettata (EmotionMeter: A Multimodal Framework for Recognizing Human Emotions p. 5)

Inoltre, il posizionamento degli elettrodi è mostrato nella figura a seguire:




fig.3 Disposizione degli elettrodi EEG comprende 62 canali, tra cui sei elettrodi temporali simmetrici (EmotionMeter: A Multimodal Framework for Recognizing Human Emotions p. 5)

È possibile trovare quattro cartelle e due file nella cartella del set di dati.



Sebbene il dataset includa sia i dati grezzi che quelli pre-processati relativi ai segnali EEG, il nostro lavoro si concentra principalmente sull'analisi e l'elaborazione dei non processati. Si è fatto dunque riferimento alla cartella "eeg\_raw\_data" la quale contiene i segnali EEG grezzi dei 15 partecipanti. Le 3 cartelle interne denominate '1', '2' e '3' corrispondono alle 3 sessioni. Ogni file ".mat" (denominato con {SubjectName}\_{Date}.mat) nelle cartelle memorizza una struttura con campi denominati "cz\_eeg1", "cz\_eeg2", ... , "cz\_eeg24", che corrispondono ai segnali EEG registrati durante le 24 prove. Ogni segnale presenta 62 canali.

Segue una rappresentazione schematica della struttura del dataset.

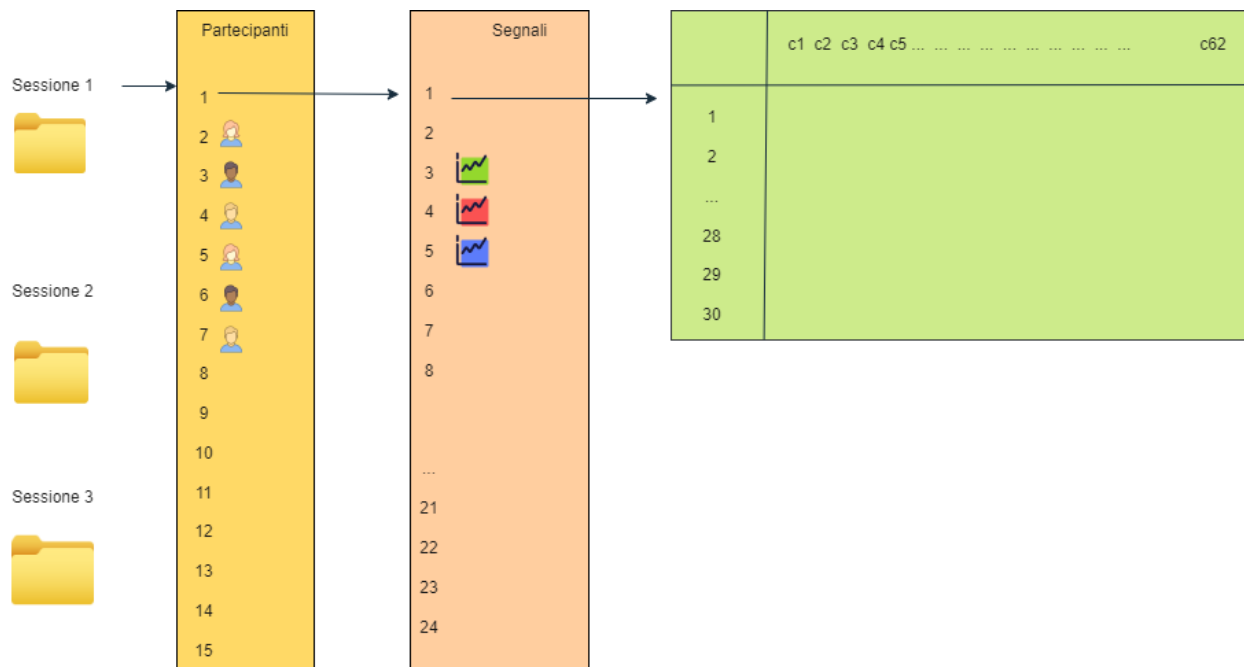


fig.4 Organizzazione del dataset descritto precedentemente mettendo in evidenza le sessioni e la strutturazione gerarchica delle cartelle all'interno di essi

Per quanto riguarda i movimenti oculari, anche qui il dataset fornisce sia i dati grezzi che quelli preprocessati.

Eye movement parameters	Extracted features
Pupil diameter (X and Y)	Mean, standard deviation and DE features in four bands: 0-0.2 Hz, 0.2-0.4 Hz, 0.4-0.6 Hz, and 0.6-1 Hz
Dispersion (X and Y)	Mean, standard deviation
Fixation duration (ms)	Mean, standard deviation
Blink duration (ms)	Mean, standard deviation
Saccade	Mean, standard deviation of saccade duration (ms) and saccade amplitude (°)
Event statistics	Blink frequency, fixation frequency, maximum fixation duration, total fixation dispersion, maximum fixation dispersion, saccade frequency, average saccade duration, average saccade amplitude, and average saccade latency.

fig.5 Lista dettagliata delle caratteristiche dei movimenti oculari (<https://bcmi.sjtu.edu.cn/~seed/seed-iv.html>)

Per il nostro studio sono stati utilizzati quelli già processati e in particolare si è fatto riferimento alla cartella “*eye\_feature\_smooth*”. Quest’ultima contiene le caratteristiche estratte dai file nella cartella *eye\_raw\_data*. La denominazione dei file segue la formazione “{SubjectName}\_{date}.mat”. La struttura di ogni file è mostrata nella figura seguente.

名称	值
eye_1	31x42 double
eye_10	31x42 double
eye_11	31x12 double
eye_12	31x27 double
eye_13	31x54 double
eye_14	31x42 double
eye_15	31x64 double
eye_16	31x35 double
eye_17	31x17 double
eye_18	31x44 double
eye_19	31x35 double
eye_2	31x23 double
eye_20	31x12 double
eye_21	31x28 double
eye_22	31x28 double
eye_23	31x43 double
eye_24	31x34 double
eye_3	31x49 double
eye_4	31x32 double
eye_5	31x22 double
eye_6	31x40 double
eye_7	31x38 double
eye_8	31x52 double
eye_9	31x36 double

	1	2	3	4	5	6
1	99.2882	99.2859	99.2790	99.2645	99.2414	99.2134
2	68.4091	68.4153	68.4242	68.4191	68.4046	68.3803
3	7.0138	7.0159	7.0195	7.0224	7.0216	7.0207
4	7.3330	7.3317	7.3309	7.3320	7.3325	7.3341
5	25.2333	25.2331	25.2328	25.2323	25.2316	25.2308
6	25.5633	25.5632	25.5628	25.5623	25.5616	25.5608
7	15.3535	15.3545	15.3559	15.3565	15.3551	15.3522
8	13.4674	13.4668	13.4678	13.4677	13.4684	13.4662
9	24.1459	24.1460	24.1464	24.1462	24.1455	24.1445
10	24.4782	24.4784	24.4787	24.4785	24.4778	24.4768
11	15.3518	15.3516	15.3516	15.3517	15.3517	15.3514
12	13.3843	13.3838	13.3840	13.3836	13.3823	13.3795
13	11.5708	11.5688	11.5642	11.5640	11.5575	11.5496
14	15.3001	15.3044	15.3115	15.3119	15.2953	15.2787
15	13.5326	13.5415	13.5515	13.5690	13.5683	13.5683
16	15.8607	15.8714	15.8894	15.9078	15.8861	15.8675
17	212.8664	212.8262	212.8850	213.0131	213.2278	213.4783
18	149.1297	149.0914	149.1429	149.2756	149.4876	149.7082
19	83.4499	83.4600	83.4677	83.4799	83.4918	83.5096
20	7.2033	7.2069	7.2101	7.2159	7.2202	7.2262
21	23.7668	23.7757	23.7795	23.7821	23.7851	23.7963
22	5.2791	5.2811	5.2832	5.2871	5.2917	5.2978
23	0.5000	0.5000	0.5000	0.5000	0.5000	0.5000
24	2.5000	2.5000	2.5000	2.5000	2.5000	2.5000
25	2.8945e...	2.8945e...	2.8945e...	2.8945e...	2.8945e...	2.8945e...
26	1.2130e...	1.2130e...	1.2130e...	1.2130e...	1.2130e...	1.2130e...
27	326.1000	326.1000	326.1000	326.1000	326.1000	326.1000
28	2.5000	2.5000	2.5000	2.5000	2.5000	2.5000
29	83.6000	83.6000	83.6000	83.6000	83.6000	83.6000
30	7.1000	7.1000	7.1000	7.1000	7.1000	7.1000
31	315.1000	315.1000	315.1000	315.1000	315.1000	315.1000

fig.6 Struttura organizzata dei dati dei movimenti oculari (<https://bcmi.sjtu.edu.cn/~seed/seed-iv.html>)

La parte sinistra mostra 24 campi; ogni campo è per una sessione. La parte destra mostra la matrice di dati in uno dei campi. Ogni riga corrisponde a un tipo di caratteristica e ogni colonna corrisponde a un campione di dati. La relazione tra il numero di riga e il tipo di elemento è

- 1-12 : Diametro pupilla (X e Y)
- 13-16: Dispersione (X e Y)
- 17-18: Durata della fissazione (ms)
- 19-22: Saccade
- 23-31: Eventi statistici

I dettagli sul dataset sono descritti sul sito ufficiale in [10].

### 3.2 Pre-processing

Come precedentemente menzionato nell'introduzione, al fine di ottenere risultati significativi, potrebbe essere necessario utilizzare tecniche di pre-processing per eliminare informazioni ridondanti o inconsistenti e conservare solo quelle essenziali per l'analisi.

Per quanto riguarda i segnali EEG la scelta di utilizzare i dati grezzi e non già quelli pre-processati è motivata dal desiderio di avere più controllo sugli elementi da eliminare così da non perdere informazioni che potrebbero essere utili in fase di analisi. Inoltre, ci siamo posti l'obiettivo di determinare se tali tecniche potessero apportare un contributo significativo a futuri sviluppi, o almeno confermare le ricerche nelle varie pubblicazioni scientifiche.

Nella letteratura relativa ai segnali EEG, diversi lavori, come indicato in [11], [12], [13], [14], [15], [16], hanno utilizzato molteplici tecniche. Per valutare le relative caratteristiche positive e negative di ciascuna di esse, abbiamo fatto riferimento alle seguenti survey: [17], [18], [19]. Inoltre, nel lavoro di tesi riportato in [20], sono state specificate le tecniche utilizzate per il pre-processing dei segnali EEG, insieme alla percentuale di menzioni presenti in letteratura dal 2015 al 2022 (analizzando complessivamente 60 articoli). Dallo studio menzionato, emerge che i tre algoritmi più utilizzati sono: PCA (50.1%), ICA (26.8%) e CSP (17.7%).

In questo lavoro, innanzitutto i dati sono stati pre-processati **decimando da 1000 Hz a 200 Hz la frequenza di campionamento dell'acquisizione**.

Successivamente è stato utilizzato un **filtro mediana** poiché è meno suscettibile agli outliers rispetto ad altri tipi di filtri. Pertanto, risulta particolarmente efficace nella gestione di artefatti o disturbi che possono avere valori molto divergenti rispetto al resto del segnale EEG.

Ai dati EEG successivamente viene applicato un **filtro Notch a 50 Hz** utilizzato per eliminare interferenze specifiche, come la frequenza di alimentazione di corrente alternata (50 Hz o 60 Hz) o i suoi armonici. [15]

Successivamente viene applicato un **filtro passa-banda** con una banda di **frequenza compresa tra 1 e 35 Hz**. Questo perché le attività neurali di interesse nell'EEG, come le onde cerebrali, si verificano generalmente all'interno di una gamma di frequenza compresa tra 1 e 35 Hz. Infatti, le frequenze inferiori a 1 Hz possono essere influenzate da drift, che è una variazione graduale e continua del segnale nel tempo. Questo può essere causato da fattori come la dissipazione di carica degli elettrodi o cambiamenti nella conduttività della pelle. D'altra parte, le frequenze superiori a 35 Hz possono essere affette da rumori ad alta frequenza o artefatti di registrazione. Questi possono includere interferenze elettriche ambientali, artefatti di movimento muscolare o artefatti generati dagli elettrodi stessi.

Dopo ancora viene applicata la **Trasformata di Wavelet**. Essa offre numerosi vantaggi nel pre-processing di tali segnali. A differenza di altre trasformate, come la Trasformata di Fourier, la Trasformata di Wavelet fornisce informazioni sulla localizzazione temporale delle caratteristiche del segnale. Questo è particolarmente rilevante per gli EEG, poiché consente di identificare specifici eventi o pattern di attività cerebrale in determinati intervalli di tempo. Offre anche adattabilità alla forma d'onda dei segnali EEG. Questi segnali sono spesso non stazionari, con variazioni rapide e transitorie nel tempo. La Trasformata di Wavelet è in grado di catturare meglio queste variazioni dinamiche, adattandosi alle forme d'onda complesse dei segnali. Ciò consente di identificare e analizzare caratteristiche significative a diversi livelli temporali, contribuendo a una comprensione più approfondita dell'attività cerebrale. Un altro aspetto importante è la capacità di *compressione dei dati*. Utilizzando la Trasformata di Wavelet, è possibile ridurre la dimensione dei dati senza perdere informazioni significative. Ciò può contribuire a ridurre il carico computazionale e migliorare l'efficienza nell'elaborazione e nell'archiviazione dei dati EEG. Infine, la Trasformata di Wavelet può essere utilizzata per il de-noising dei segnali EEG.

E infine abbiamo applicato il **filtro Savitzky-Golay** il quale è un metodo utilizzato nell'elaborazione del segnale. I filtri di Savitzky-Golay sono spesso preferiti, perché quando sono opportunamente progettati per adattarsi alla forma d'onda di un segnale corrotto dal rumore, tendono a preservare la larghezza e l'altezza dei

picchi nella forma d'onda del segnale ovvero aumentare la precisione dei dati senza distorcere la tendenza del segnale. [25]



fig.7 Segnale prima del pre-processing




fig.8 Segnale dopo il pre-processing

### 3.3 Riduzione della dimensionalità con PCA

**PCA** (Principal Component Analysis) è un metodo analitico multivariato basato sulla trasformazione lineare che spesso viene utilizzato per ridurre la dimensionalità dei dati, estrarre informazioni significative da grandi quantità di dati, analizzare le strutture delle variabili, etc. [22,23].

In questo studio il metodo PCA è stato utilizzato per la riduzione della dimensionalità dei segnali EEG. Poiché la risoluzione spaziale del segnale EEG è scarsa, considerare tutti i canali per l'estrazione delle caratteristiche aumenta solo il carico di lavoro. In questa situazione, possiamo utilizzare l'analisi delle componenti principali (PCA) perché è in grado di individuare la massima variazione all'interno di dimensioni elevate dell'input. Pertanto, per ridurre il numero di canali di interesse, un gruppo di segnali EEG può essere trasformato in un singolo segnale utilizzando la PCA.

Seguendo il seguente studio [1] il gruppo frontale è stato costruito considerando i seguenti canali: F7, F5, F3, F1, FZ, F2, F4, F6 e F8. Abbiamo applicato la PCA su questi nove canali e preso la prima componente principale (PCA). La procedura simile è stata applicata ai gruppi di lobi *pre-frontale*, *frontale*, *centrale*, *parietale* e *occipitale* e tutti i segnali sono stati trasformati in cinque segnali di interesse di ogni set del segnale EEG di input. Questa procedura ha ridotto i 64 canali iniziali del segnale EEG in 5 set di dati di input. Il numero di canali con i loro gruppi e i canali esclusi sono presentati graficamente nella seguente figura.

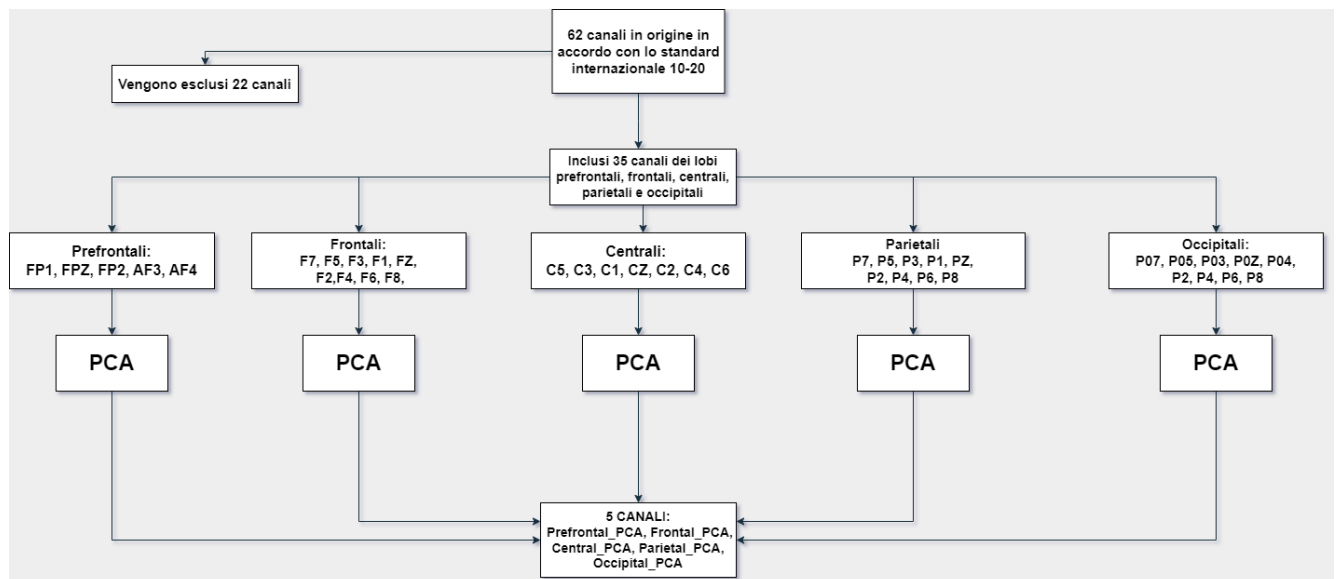


fig.9 Rappresentazione schematica dell'applicazione della PCA (Principal Component Analysis)



fig.10 Segnali dopo aver applicato la PCA



### 3.4 Estrazione delle caratteristiche

Nel corso delle nostre ricerche, abbiamo esaminato diversi approcci per l'estrazione delle caratteristiche nel contesto dell'analisi dei segnali. Inizialmente, la Power Spectral Density (PSD) è stata presa in considerazione come una delle tecniche più promettenti. Tuttavia, durante le sperimentazioni, abbiamo scoperto che la PSD potrebbe non essere ottimale per i nostri obiettivi. Nonostante la PSD fornisca informazioni sull'energia nelle diverse bande di frequenza, potrebbe non essere in grado di catturare le informazioni più rilevanti per distinguere le diverse emozioni nel nostro contesto.

Per l'estrazione delle caratteristiche dei segnali EEG si è preferito utilizzare la combinazione di statistiche e misure, più precisamente con la concatenazione della *media* (mean), *deviazione standard* (std), *deviazione assoluta mediana* (mad), *massimo* (max), *minimo* (min), *range interquartile* (IQR), *entropia di Shannon* ed *energia*. Più precisamente:

1. **Media (mean):** La media è una misura che rappresenta il valore medio di un insieme di dati. La media fornisce un'indicazione del livello generale di attività elettrica cerebrale presente nel segnale. Ad esempio, durante situazioni di stress o emozioni intense, potrebbe verificarsi un aumento o una diminuzione della media del segnale EEG rispetto allo stato di riposo o ad uno stato emotivamente neutro.
2. **Deviazione standard (std):** La deviazione standard è una misura di dispersione che indica quanto i dati si discostano dalla media. Nel contesto dell'EEG, la deviazione standard riflette la variabilità dei valori del segnale intorno alla media. Una deviazione standard maggiore indica una maggiore variazione dei valori del segnale e potrebbe indicare una maggiore variabilità nell'attività cerebrale legata alle emozioni.
3. **Deviazione assoluta mediana (mad):** La deviazione assoluta mediana è una misura robusta della dispersione dei dati, che riduce l'influenza di valori estremi o outliers. Viene calcolata calcolando la mediana dei valori assoluti delle differenze tra i dati e la mediana dei dati stessi. Nel contesto dell'EEG, il mad cattura la dispersione dei valori del segnale intorno alla mediana e fornisce una misura della variabilità robusta rispetto agli outliers.
4. **Massimo (max) e Minimo (min):** Il massimo e il minimo rappresentano rispettivamente il valore più alto e il valore più basso presenti nel segnale EEG. I valori massimi indicano i punti salienti e le variazioni estreme del segnale, mentre i valori minimi possono indicare anomalie o segnali di bassa intensità. Identificare questi valori può essere utile per individuare eventi di picco o anomalie che possono essere rilevanti per l'analisi.
5. **Range interquartile (IQR):** L'intervallo interquartile è una misura di dispersione che indica l'ampiezza dell'intervallo che contiene il 50% centrale dei dati. Viene calcolato come la differenza tra il terzo quartile (il valore al 75% dei dati ordinati) e il primo quartile (il valore al 25% dei dati ordinati). Nel contesto dell'EEG, l'IQR rappresenta la variazione dei valori del segnale nella fascia centrale dei dati e può aiutare a individuare possibili asimmetrie o differenze nella concentrazione dei dati intorno alla mediana, fornendo ulteriori informazioni sulla forma della distribuzione dei dati.
6. **Entropia di Shannon:** L'entropia di Shannon è una misura dell'incertezza o della complessità di un insieme di dati. Nel contesto dell'EEG, l'entropia di Shannon può essere calcolata utilizzando la distribuzione di probabilità dei valori del segnale. Un'entropia di Shannon più elevata può suggerire una maggiore diversità o variabilità nel segnale, mentre un'entropia più bassa può indicare una maggiore regolarità. Essa può fornire indicazioni sulla presenza di pattern o regolarità del segnale.
7. **Energia:** L'energia è una misura che rappresenta la quantità totale di potenza contenuta nel segnale. Nel contesto dell'EEG, l'energia può essere calcolata sommando i valori quadri dei campioni del segnale. L'energia riflette l'ampiezza complessiva del segnale e può essere utilizzata per valutare l'intensità o l'attività generale del segnale EEG.

### 3.5 Protocolli

Nel presente studio vengono utilizzati 3 differenti protocolli:

- **Protocollo Subject-Dependent** (dipendente dal soggetto): La divisione "subject dependent" è una tecnica di suddivisione dei dati basata sui soggetti o partecipanti coinvolti nello studio. Per ogni partecipante selezioniamo casualmente 16 segnali come set di addestramento e i restanti 8 per il test. In ogni assegnazione casuale, ci assicuriamo che ci siano due campioni da ogni categoria di etichette nel set di test, per garantire un bilanciamento delle classi in questo dataset relativamente più piccolo. Il risultato finale viene, infine, determinato facendo la media su tutti i soggetti e le 3 sessioni.

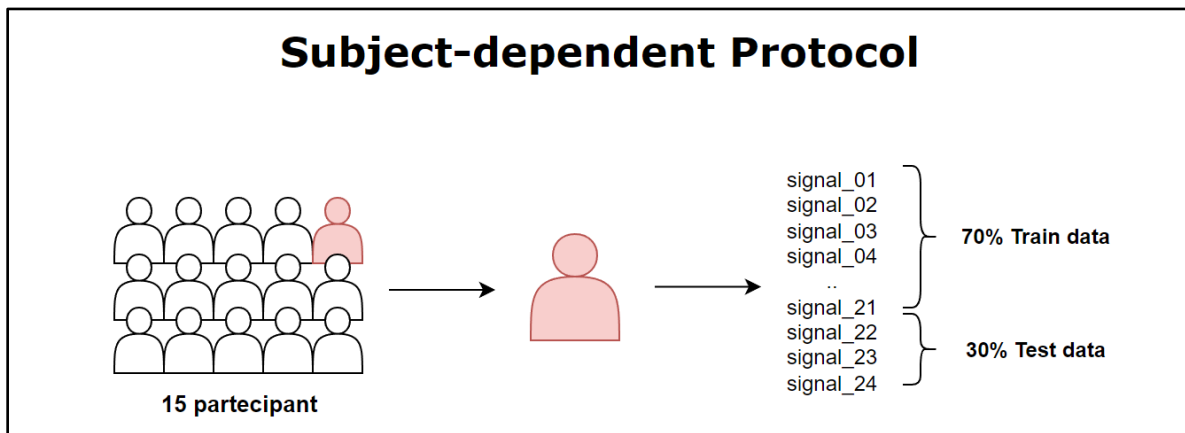


fig.11 Rappresentazione schematica del protocollo Subject-dependent

- **Protocollo Subject-Independent** (indipendente dal soggetto): Nella letteratura scientifica, l'uso di tale divisione è ampiamente riconosciuto come un metodo affidabile per valutare in modo realistico l'accuratezza del modello su nuovi partecipanti. Questo approccio riduce il rischio di overfitting e promuove la generalizzazione del modello, consentendo di identificare modelli di segnali EEG comuni tra diversi partecipanti. L'accuratezza valutata su nuovi partecipanti non utilizzati durante l'addestramento offre una stima più realistica delle capacità del modello nell'affrontare la variabilità individuale e nel riconoscimento dei modelli dei segnali. Adottiamo l'approccio utilizzato in [24] realizzando il *leave-one-subject-out-cross-validation*. Eseguiamo questa validazione incrociata per ogni sessione, in cui i dati di 14 soggetti vengono utilizzati per l'addestramento e 1 per il test. I risultati vengono poi mediati sulle 3 sessioni.

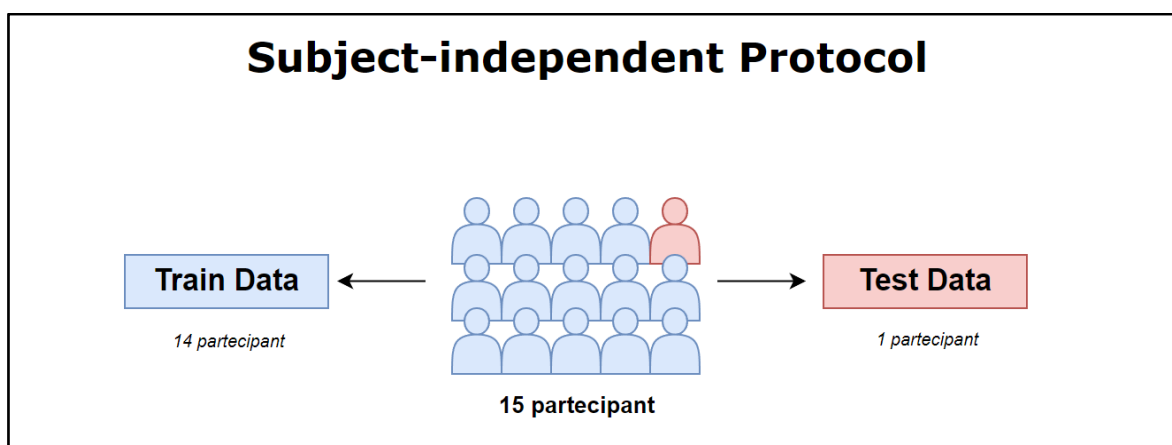


fig.12 Rappresentazione schematica del protocollo Subject-independent

- **Protocollo Subject-Biased** (parzialmente dipendente dal soggetto): In questo protocollo all'interno del set di dati, il 20% dei campioni di ciascun soggetto nella stessa prova viene designato casualmente per il test, mentre il resto per l'addestramento. Dunque non applichiamo alcuna suddivisione in soggetti e sessioni ma li applichiamo su tutti i segnali che sono presenti nel dataset SEED-IV.

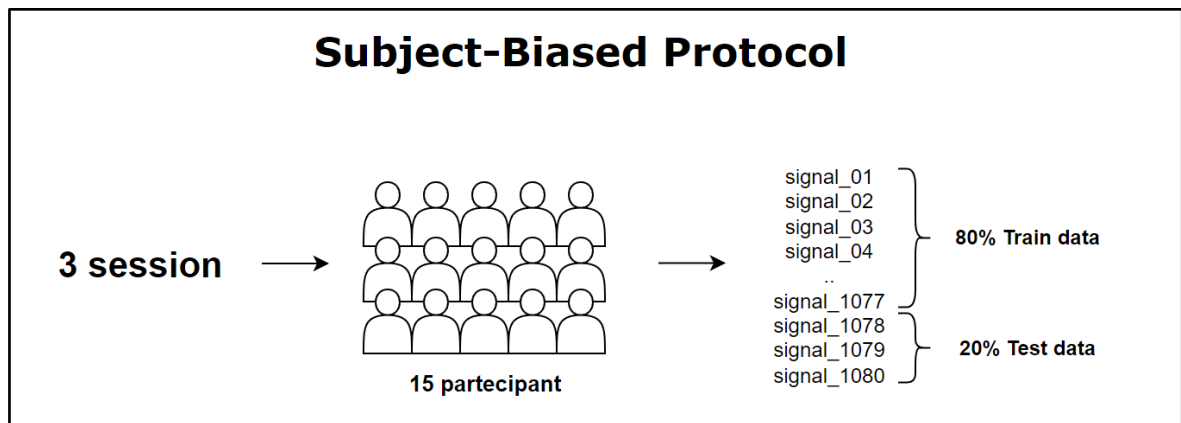


fig.13 Rappresentazione schematica del protocollo Subject-biased

### 3.6 Fusione con i movimenti oculari

Dopo l'analisi dei segnali EEG, sono stati aggiunti i movimenti oculari come ulteriore modalità biometrica per ottenere informazioni complementari. Queste due biometrie sono state unite tramite la **fusione a livello di caratteristiche (feature level fusion)**. Si tratta di una tecnica utilizzata nell'ambito dei sistemi multibiometrici che combina le caratteristiche estratte da ciascuna modalità biometrica per formare un vettore di caratteristiche combinato. Abbiamo combinato le caratteristiche rilevanti estratte dai segnali EEG con le caratteristiche fornite dal dataset relative ai movimenti oculari utilizzando la tecnica di **concatenazione**. La feature level fusion attraverso la concatenazione offre il vantaggio di mantenere tutte le informazioni estratte dalle modalità originali senza perdita di dati. Segue una visualizzazione schematica di quanto detto:

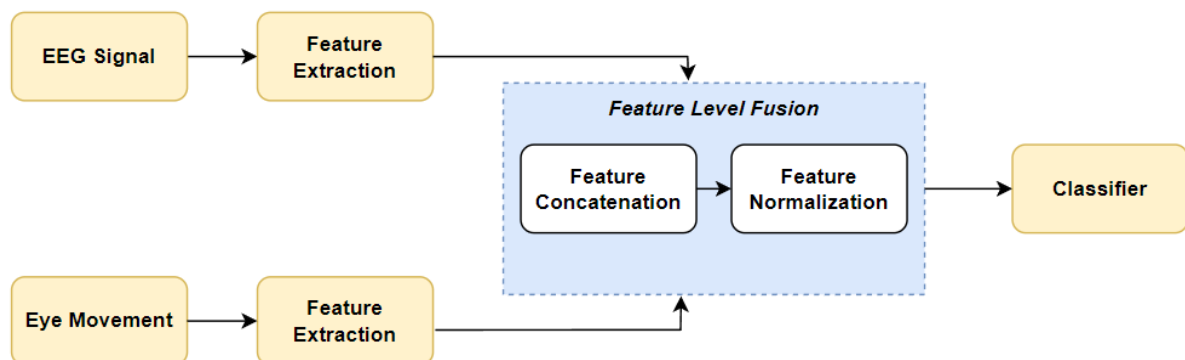


fig.14 Rappresentazione schematica della tecnica di fusione *Feature Level Fusion*



### 3.7 Classificazione

In questo lavoro, abbiamo impiegato sei modelli di apprendimento automatico per la classificazione dei dati emotivi dell'EEG: SVM (Support Vector Machine), XGBoost, Random Forest, Logistic Regression, Naive Bayes ed Adaboost. Di seguito è presentata una breve descrizione di questi algoritmi:

1. **XGBoost:** è un algoritmo di apprendimento automatico basato su gradient boosting. È progettato per affrontare problemi di classificazione e regressione. XGBoost costruisce un insieme di modelli di alberi decisionali in sequenza, in cui ogni nuovo modello cerca di correggere gli errori residui dei modelli precedenti. Utilizza tecniche di ottimizzazione per migliorare l'accuratezza dei modelli, come la regolarizzazione per evitare l'overfitting e la gestione efficiente delle funzioni mancanti o dei valori anomali.
2. **Support Vector Machine (SVM):** è un algoritmo di apprendimento automatico supervisionato utilizzato per la classificazione e la regressione. L'obiettivo di SVM è trovare un iperpiano ottimale che separi i dati di addestramento in diverse classi. L'algoritmo cerca di massimizzare la distanza tra i punti di dati più vicini a ciascuna classe, chiamati vettori di supporto, al fine di ottenere la migliore separazione.
3. **Random Forest:** Random Forest è un algoritmo di apprendimento automatico basato su ensemble di alberi decisionali. Crea una collezione di alberi decisionali, ciascuno addestrato su un sottoinsieme casuale dei dati di addestramento e utilizza il voto maggioritario dei singoli alberi per fare predizioni. Random Forest è in grado di gestire sia problemi di classificazione che di regressione ed è noto per la sua robustezza contro il rumore e la presenza di caratteristiche irrilevanti nel set di dati.
4. **Logistic Regression (Regressione Logistica):** La regressione logistica è un algoritmo di apprendimento automatico utilizzato per la modellazione e la previsione di variabili dipendenti binarie o categoriche. Questo algoritmo si basa su un modello matematico chiamato funzione logistica o sigmoide. Questa funzione assume valori compresi tra 0 e 1 e ha una forma a "S". La funzione sigmoide viene utilizzata per trasformare una combinazione lineare delle caratteristiche di input in una probabilità compresa tra 0 e 1. Durante il processo di addestramento della regressione logistica, gli attributi (variabili indipendenti) dei dati di addestramento vengono utilizzati per calcolare i pesi o i coefficienti delle caratteristiche. Questi pesi indicano l'importanza relativa di ciascuna caratteristica nel processo decisionale. L'obiettivo dell'addestramento è minimizzare l'errore tra le probabilità predette dal modello e le etichette di classe reali nei dati di addestramento.
5. **Naive Bayes:** è un algoritmo di apprendimento automatico basato sul teorema di Bayes con l'assunzione di indipendenza condizionale tra le variabili. Naive Bayes è ampiamente utilizzato per la classificazione di testi e la categorizzazione di documenti, ma può essere applicato anche ad altri tipi di dati. L'algoritmo calcola le probabilità condizionali delle classi date le caratteristiche dei dati e fa la previsione scegliendo la classe con la probabilità più alta.
6. **Adaboost:** è un algoritmo di apprendimento automatico basato su ensemble, che combina diversi modelli deboli per creare un classificatore forte. Adaboost funziona iterativamente assegnando un peso maggiore agli esempi di addestramento classificati erroneamente in ogni iterazione. Gli errori sono corretti concentrando sugli esempi più difficili. Adaboost è noto per essere efficace nel gestire problemi di classificazione binaria e multiclasse.

Ogni modello è stato applicato sui 3 protocolli specificati prima Subject-Dependent, Subject-Independent e Subject-Biased. La suddivisione dei dati in queste tre versioni ha permesso di valutare l'efficacia dei modelli in diversi contesti e di comprendere meglio i loro punti di forza e le loro limitazioni.

## 4. Tecnologie utilizzate

Durante lo sviluppo del lavoro, sono state utilizzate diverse tecnologie e risorse che hanno svolto un ruolo fondamentale nello sviluppo e nella condivisione dei documenti e dei risultati. Tra queste, sono state impiegate **Colab** e **Google Drive** come strumenti chiave.

Colab è stata una componente essenziale dell'ambiente di sviluppo. Si tratta di una piattaforma basata su cloud che fornisce un ambiente di notebook interattivo offerto da Google. Attraverso Colab, è stato possibile sfruttare un'infrastruttura di calcolo potente ed efficiente per eseguire il codice Python. Con Google Drive è stato possibile archiviare e organizzare i file di progetto, incluso il dataset, notebook di Colab, risultati delle analisi e documenti di presentazione.

Durante il lavoro, sono state utilizzate diverse librerie di machine learning. Ad esempio, la libreria *Numpy* è stata impiegata per eseguire operazioni matematiche e manipolare i dati in formato di array. La libreria *Pandas* è stata utilizzata per la gestione e la manipolazione dei dati in quanto i segnali erano multicanali. Inoltre, la libreria **Joblib** ha consentito di salvare e caricare i modelli addestrati in modo efficiente.

Per quanto riguarda i modelli, la libreria **Sklearn (scikit-learn)**, ha svolto un ruolo essenziale nella loro implementazione, la quale fornisce una vasta gamma di strumenti per la preparazione dei dati, la creazione dei modelli e il calcolo di metriche di valutazione come accuratezza, precisione, richiamo, F1-score, matrice di confusione.

La libreria **Seaborn** è stata utilizzata per creare visualizzazioni grafiche dei dati, come mappe di calore e grafici informativi, al fine di analizzare e rappresentare in modo efficace i risultati delle analisi.

Inoltre, è stato utilizzato il framework **Optuna**, che ha consentito di ottimizzare gli iperparametri dei modelli di machine learning. Optuna è un ottimizzatore iperparametrico che ha contribuito a raffinare la configurazione dei modelli, permettendo di ottenere prestazioni ottimali e di evitare fenomeni di *overfitting* o *underfitting* dei dati.

Con Optuna è stato possibile esplorare in modo efficiente lo spazio degli iperparametri e individuare le migliori combinazioni di parametri per ottenere prestazioni ottimali dai modelli.

## 5. Risultati

Prima di applicare i modelli abbiamo utilizzato il framework Optuna per identificare i migliori iperparametri. Le combinazioni ottenute sono state salvate in file dedicati all'interno della cartella OneDrive. Successivamente, abbiamo estratto la combinazione ottimale di parametri e memorizzato il modello risultante. Ciò ci ha permesso di utilizzare il modello nei 3 protocolli. Per poter ottenere i migliori risultati possibili abbiamo effettuato 50 iterazioni.

Qui in tabella specifichiamo le accuratze ottenute per ogni protocollo con i migliori iperparametri individuati da Optuna:

	Subject Dependent	Subject Independent	Subject Biased
<b>XGBoost</b>	<b>78%</b>	91%	<b>85%</b>
<b>SVM</b>	64%	89%	80%
<b>Random Forest</b>	<b>53%</b>	<b>92%</b>	83%
<b>Logistic Regression</b>	68%	90%	81%
<b>Naive Bayes</b>	70%	<b>85%</b>	<b>63%</b>
<b>AdaBoost</b>	75%	86%	63%

Come possiamo vedere dalla tabella per quanto riguarda il protocollo Subject Dependent il modello che ci dà miglior accuratezza è **XGBoost** (Acc:78%) e la peggiore è **Random Forest** (Acc:53%); per Subject Independent abbiamo miglior accuratezza Random Forest (Acc:92%) e peggiore Naive Bayes (Acc:85%), e per Subject Biased abbiamo migliore accuratezza XGBoost (Acc:85%) e peggiore Naive Bayes (Acc:63%).

Inoltre, come si può notare i risultati più alti sono ottenuti col protocollo Subject-Independent. Si ottiene situazione ideale poiché il protocollo Subject Independent è progettato per valutare l'efficacia di un algoritmo di classificazione delle emozioni in modo indipendente dal soggetto. Questo consente una maggiore affidabilità e accuratezza in quanto il modello deve imparare i modelli comuni che caratterizzano le emozioni e non solo adattarsi alle caratteristiche specifiche di un singolo soggetto. Inoltre, siccome è stato addestrato e testato su gruppi di soggetti diversi, i risultati sono più *generalizzabili* e possono essere confrontati con altri studi condotti utilizzando lo stesso protocollo.

Dall'analisi effettuata, possiamo dedurre che **XGBoost** è un modello molto promettente per il riconoscimento delle emozioni. Sebbene nella valutazione Subject Independent sia stato superato da Random Forest, la differenza tra i due modelli è di soli 1%. Pertanto, possiamo ancora considerare XGBoost come uno dei migliori modelli disponibili per questo compito.

D'altra parte, Naive Bayes ha mostrato una performance discreta ma con accuratze più basse rispetto agli altri modelli. Non possiamo considerarlo come il modello migliore, ma potrebbe ancora essere utile in alcune situazioni.

Oltre a ciò, c'è da considerare che il valore ottenuto da Subject Independent è un valore mediato tra tutte le iterazioni dei partecipanti (*cross validation*) e tra le 3 sessioni. Quindi andando a vedere le varie accuratezza di ogni iterazione notiamo che a volte l'accuratezza sfiora l'unità con un 98% e altre volte si abbassa su 86%.

Questa situazione potrebbe anche essere derivata da una delle limitazioni del dataset SEED-IV. Le etichette fornite dal dataset, cioè le classi di emozioni assegnate ad ogni video sono rispettive del video visionato e non è relativo all'emozione dei partecipanti. Pertanto, le valutazioni dei partecipanti dopo la visione dei video non sono state prese in considerazione per l'annotazione di questo dataset. Quindi ad esempio potrebbe essere che un video è stato etichettato come "Happy" ma il partecipante ha provato un'emozione di tristezza.

Questa informazione ovviamente non annulla tutto il lavoro effettuato su questo dataset. Ma potrebbe essere utile in analisi e studi futuri quello di utilizzare le valutazioni dei partecipanti.

Oltre a memorizzare il miglior modello come menzionato in precedenza, abbiamo calcolato diverse metriche di accuratezza su questa configurazione ottimizzata. I valori delle metriche sono stati salvati in un file CSV per agevolarne la consultazione e l'analisi successiva. come illustrato nella figura sottostante:

	A	B	C	D	E
1	Model	Accuracy	Precision	Recall	F1-score
2	RF	0.9583333333	0.9642857143	0.9583333333	0.958041958

fig. 15 Resoconto delle metriche di valutazione

Al fine di ottenere una rappresentazione visiva chiara delle prestazioni del modello, abbiamo generato le matrici di confusione. Questa matrice rappresenta i risultati predittivi del modello rispetto alle etichette effettive nel set di dati. La matrice di confusione è stata salvata in una cartella apposita in formato PDF.




fig. 16 Matrice di confusione prodotta a seguito dell'esecuzione di XGBoost




fig. 17 Matrice di confusione prodotta a seguito dell'esecuzione di SVM




fig.18 Matrice di confusione prodotta a seguito dell'esecuzione di Random Forest

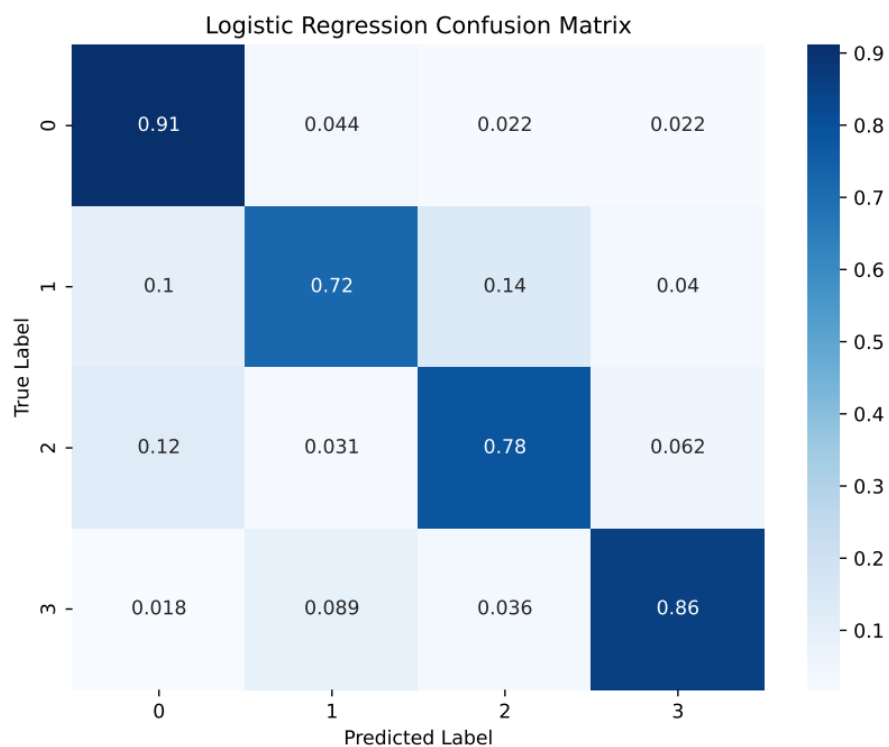


fig.19 Matrice di confusione prodotta a seguito dell'esecuzione di Logistic Regression

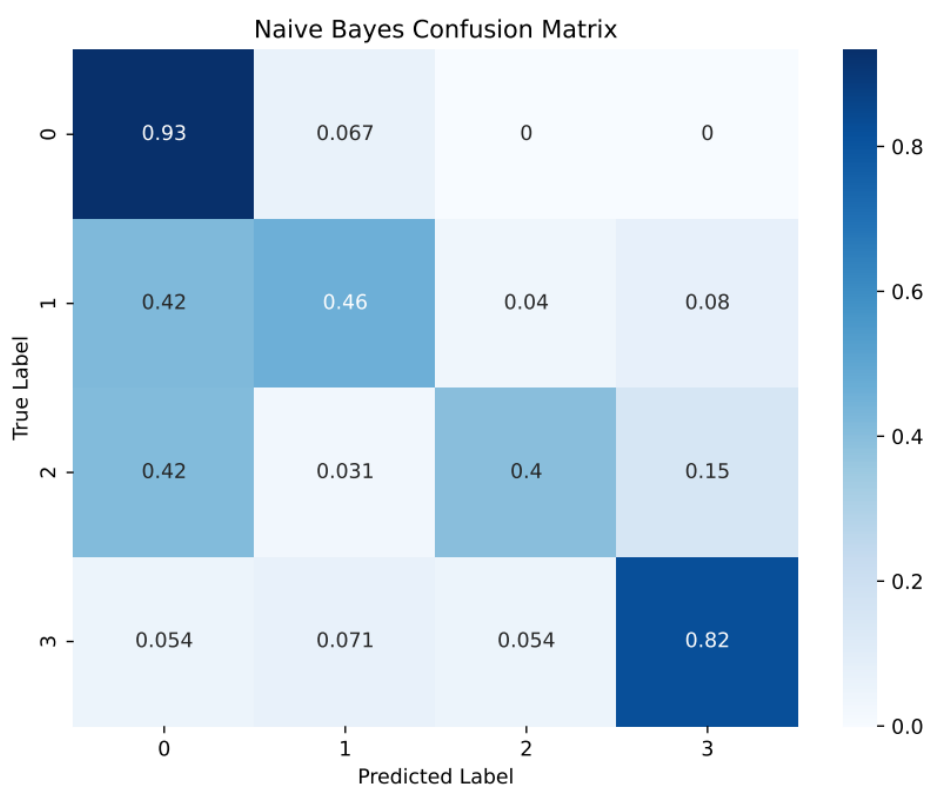


fig.20 Matrice di confusione prodotta a seguito dell'esecuzione di Naive Bayes

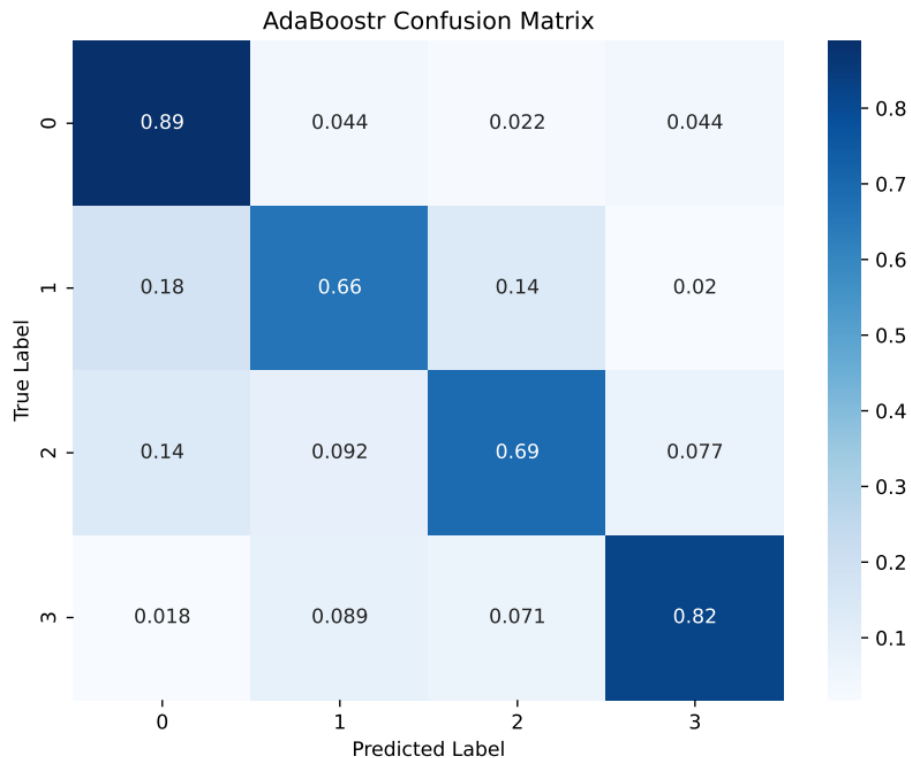


fig.21 Matrice di confusione prodotta a seguito dell'esecuzione di AdaBoost

Si considerano le matrici di confusione del protocollo Subject-Biased in quanto forniscono informazioni più utili riguardanti il comportamento dei vari modelli. Le emozioni sono rispettivamente: 0 (neutralità), 1 (tristezza), 2 (paura), 3 (felicità).

L'analisi delle matrici di confusione dei sei modelli evidenzia che la classe 0, corrispondente all'emozione della neutralità, ha il valore di True Positive più alto. Questo indica che la neutralità è l'emozione più facile da comprendere per tutti i modelli presi in considerazione.

Focalizzandoci sulle matrici di confusione più significative, possiamo osservare che il modello XGBoost, Random Forest e Logistic Regression hanno una maggiore capacità di distinguere correttamente tra neutralità e felicità ma si comportano bene anche nel riconoscimento delle altre due emozioni.

SVM ha mostrato delle difficoltà nel riconoscimento dell'emozione della tristezza. In particolare, ha commesso un errore tollerabile nel confondere la neutralità con la felicità, ma ci preoccupa il fatto che abbia confuso la paura e la felicità con la tristezza. Questa è una situazione non ideale in quanto i segnali EEG possono essere utilizzati per studiare la depressione.

Naive Bayes mostra una migliore discriminazione per le emozioni di neutralità e felicità rispetto alle altre due emozioni, ma commette errori nel confondere la tristezza e la paura con la neutralità. Ma questa è comunque una situazione preferibile rispetto a SVM. Infatti, sebbene SVM possa avere un'accuratezza complessiva migliore rispetto a Naive Bayes, potrebbe essere considerato preferibile utilizzare Naive Bayes quando l'obiettivo principale è discriminare correttamente le emozioni.

## 6. Conclusione e sviluppi futuri

In conclusione, i risultati ottenuti nel corso della ricerca suscitano un elevato livello di soddisfazione. Siamo pienamente soddisfatti dei risultati raggiunti, che mostrano un'accuratezza che si attesta intorno al 90%. Crediamo che il nostro lavoro di analisi del pre-processing e l'estrazione delle caratteristiche dei segnali EEG fornisca una solida base per ulteriori studi nell'applicazione e nella comprensione dei segnali per il riconoscimento delle emozioni.

La scelta di utilizzare tre diversi protocolli è stata fondamentale nel nostro lavoro. Ogni protocollo potrebbe avere punti di forza e debolezza diversi. Quindi l'utilizzo di più protocolli ha consentito di valutare l'affidabilità e la coerenza dei risultati ottenuti e di ottenere una visione più completa delle prestazioni dei modelli.

Dall'analisi dei sei modelli utilizzati nella ricerca, è emerso che **XGboost** si è dimostrato il modello migliore sia in termini di accuratezza sia nella corretta discriminazione delle emozioni.

È importante sottolineare che tali risultati sono stati ottenuti grazie all'espansione dell'analisi, che ha incluso i dati relativi ai movimenti oculari. L'integrazione dei dati sui movimenti oculari con la tecnica di fusione a livello di caratteristiche (**feature level fusion**) si è rivelata una scelta fondamentale per il successo dei risultati ottenuti. Questa decisione ha permesso di arricchire la comprensione delle interazioni tra emozioni e segnali, fornendo informazioni preziose sull'attenzione, l'interesse e le risposte emotive degli individui.

Per gli sviluppi futuri sarebbe interessante esplorare altre tecniche di fusione che potrebbero portare ad una maggiore accuratezza nei risultati. E applicare il nostro lavoro anche ad altri dataset presenti in letteratura per confermare i buoni risultati ottenuti.

In conclusione, il nostro lavoro di ricerca sui segnali EEG si prospetta come un contributo di rilievo per il campo, offrendo nuove prospettive e gettando solide basi per ulteriori studi. Siamo ottimiste riguardo ai potenziali benefici che i nostri risultati possono apportare, quali il miglioramento delle diagnosi, delle terapie neurologiche. Inoltre, riteniamo che le nostre analisi possano essere applicate nell'ambito dell'intelligenza artificiale, contribuendo allo sviluppo di soluzioni tecnologiche innovative.



## Bibliografia

- [1] Rahman, Md & Hossain, Md & Hossain, Mazhar & Ahmmmed, Rasel. (2019). Employing PCA and t-statistical approach for feature extraction and classification of emotion from multichannel EEG signal. *Egyptian Informatics Journal*. 21. 10.1016/j.eij.2019.10.002.
- [2] Alarcao SM, Fonseca MJ. Emotions recognition using EEG signals: a survey. *IEEE Trans Affective Comput* June 2017. doi: <https://doi.org/10.1109/TAFFC.2017.2714671>.
- [3] Ramirez R, Planas J, Escude N, Mercade J, Farriols C. EEG-based analysis of the emotional effect of music therapy on palliative care cancer patients. *Front Psychol* 2018;9(254).
- [4] Sourina O, Liu Y, Nguyen MK. Real-time EEG-based emotion recognition for music therapy. *J Multimodal User Interface* 2012;5(1-2):27-35. doi: <https://doi.org/10.3389/fpsyg.2018.00254>.
- [5] Healey JA, Picard RW. Detecting stress during real-world driving tasks using physiological sensors. *IEEE Trans Intell Transp Syst* 2005;6:156-66. doi: <https://doi.org/10.1109/TITS.2005.848368>.
- [6] Katsis CD, Katertsidis N, Ganiatsas G, Fotiadis DI. Toward emotion recognition in car-racing drivers: a biosignal processing approach. *IEEE Trans Syst Man Cybern* 2008;38:502-12. doi: <https://doi.org/10.1109/TSMCA.2008.918624>.
- [7] Ko BC. A brief review of facial emotion recognition based on visual information. *Sensors* 2018;18(401):pp. doi: <https://doi.org/10.3390/s18020401>.
- [8] Rampil, I. (1998) A Primer for EEG Signal Processing in Anesthesia. *Anesthesiology*, 89, 980-1002. <http://dx.doi.org/10.1097/00000542-199810000-00023>
- [9] Wang, Min & Yin, Xuefei & Zhu, Yanming & Hu, Jiankun. (2022). Representation Learning and Pattern Recognition in Cognitive Biometrics: A Survey. *Sensors*. 22. 10.3390/s22145111.
- [10] <https://bcmi.sjtu.edu.cn/~seed/seed-iv.html>
- [11] Yong, Xinyi & Ward, Rabab & Birch, Gary. (2008). Robust Common Spatial Patterns for EEG Signal Preprocessing. Conference proceedings : ... Annual International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE Engineering in Medicine and Biology Society. Conference. 2008. 2087-90. 10.1109/IEMBS.2008.4649604.
- [12] Shoka, Athar & Dessouky, Mohamed & el-sherbeny, Ahmed & El-Sayed, Ayman. (2019). Literature Review on EEG Preprocessing, Feature Extraction, and Classifications Techniques. *Menoufia Journal of Electronic Engineering Research*. 28. 292-299. 10.21608/mjeer.2019.64927.
- [13] Kim, Sung-Phil. (2018). Preprocessing of EEG: Methods and Applications. 10.1007/978-981-13-0908-3\_2.
- [14] Xie, Yu & Oniga, Stefan. (2020). A Review of Processing Methods and Classification Algorithm for EEG Signal. *Carpathian Journal of Electronic and Computer Engineering*. 13. 23-29. 10.2478/cjece-2020-0004.
- [15] Aggarwal, Swati & Chugh, Nupur. (2022). Review of Machine Learning Techniques for EEG Based Brain Computer Interface. *Archives of Computational Methods in Engineering*. 29. 10.1007/s11831-021-09684-6.
- [16] Elsayed, Nelly & Bayoumi, Magdy. (2017). Brain Computer Interface: EEG Signal Preprocessing Issues and Solution. *International Journal of Computer Applications*. 169. 10.5120/ijca2017914621.
- [17] A Survey of Analysis and Classification of EEG Signals for Brain-Computer Interfaces (Mohd Zaizu Ilyas, Puteh Saad & Muhammad Imran Ahmad ) 2015 <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=7235129>
- [18] A Review of Processing Methods and Classification Algorithm for EEG Signal (Yu Xie ,Stefan Oniga) 2020 <https://sciendocom/article/10.2478/cjece-2020-0004>
- [19] B. Kaliraman, S. Nain, R. Verma, M. Thakran, Y. Dhankhar and P. B. Hari, "Pre-processing of EEG signal using Independent Component Analysis," 2022 10th International Conference on Reliability, Infocom Technologies and Optimization (Trends and Future Directions) (ICRITO), Noida, India, 2022, pp. 1-5, doi: 10.1109/ICRITO56286.2022.9964717.
- [20] <https://bibdigital.epn.edu.ec/bitstream/15000/23420/1/CD%2012848.pdf>

- [21] Rahman, Md & Hossain, Md & Hossain, Mazhar & Ahmmed, Rasel. (2019). Employing PCA and t-statistical approach for feature extraction and classification of emotion from multichannel EEG signal. *Egyptian Informatics Journal*. 21. 10.1016/j.eij.2019.10.002.
- [22] Rahman MA, Milu MMH, Anjum A, Khanam F, Mollah MN, Ahmad M. 2018. Classification of motor imagery events from prefrontal hemodynamics for BCI application,” In: International Joint Conference on Computational Intelligence (IJCCI), 14-15 December, 2018, Daffodil International University, Dhaka, Bangladesh. pp. 1-06. doi: 10.1007/978-981-13-7564-4\_2
- [23]Abdi H, Williams LJ. Principal component analysis 2010;vol. 2, July/August.doi: <https://doi.org/10.1002/wics.101>.
- [24] T. Song, W. Zheng, C. Lu, Y. Zong, X. Zhang, and Z. Cui, “MPED: A multi-modal physiological emotion database for discrete emotion recognition,” *IEEE Access*, vol. 7, pp. 12177–12191, 2019.
- [25] R. W. Schafer, "What Is a Savitzky-Golay Filter? [Lecture Notes]," in *IEEE Signal Processing Magazine*, vol. 28, no. 4, pp. 111-117, July 2011, doi: 10.1109/MSP.2011.941097.
- [26] V. Bostanov, "BCI competition 2003-data sets Ib and Iib: feature extraction from event-related brain potentials with the continuous wavelet transform and the t-value scalogram," in *IEEE Transactions on Biomedical Engineering*, vol. 51, no. 6, pp. 1057-1061, June 2004, doi: 10.1109/TBME.2004.826702.
- [27] (2002). Principal Component Analysis for Special Types of Data. In: Principal Component Analysis. Springer Series in Statistics. Springer, New York, NY. [https://doi.org/10.1007/0-387-22440-8\\_13](https://doi.org/10.1007/0-387-22440-8_13)
- [28] Ahmed, M.Z.I.; Sinha, N.; Phadikar, S.; Ghaderpour, E. Automated Feature Extraction on AsMap for Emotion Classification Using EEG. *Sensors* 2022, 22, 2346. <https://doi.org/10.3390/s22062346>
- [29] Yong Zhang, Xiaomin Ji, Suhua Zhang, An approach to EEG-based emotion recognition using combined feature extraction method, *Neuroscience Letters*, Volume 633, 2016, Pages 152-157, ISSN 0304-3940, <https://doi.org/10.1016/j.neulet.2016.09.037>.
- [30] P. Ekman and W. V. Friesen, “Constants across cultures in the face and emotion,” *J. Pers. Soc. Psychol.*, vol. 17, no. 2, pp. 124–129, 1971.
- [31] R. A. Calvo and S. D’Mello, “Affect detection: An interdisciplinary review of models, methods, and their applications,” *IEEE Trans. Affect. Comput.*, vol. 1, no. 1, pp. 18–37, Jan. 2010.
- [32] Z. Zeng, M. Pantic, G. I. Roisman, and T. S. Huang, “A survey of affect recognition methods: Audio, visual, and spontaneous expressions,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 31, no. 1, pp. 39–58, Jan. 2009.
- [33] M. Y. Tsalamlal, M.-A. Amorim, J.-C. Martin, and M. Ammi, “Combining facial expression and touch for perceiving emotional valence,” *IEEE Trans. Affect. Comput.*, to be published, doi: 10.1109/TAFFC.2016.2631469.

## Dizionario

*AWICA* (l'Adaptive Weighted ICA)

*BCI* (Brain-Computer Interface)

*CSP* (Common Spatial Patterns)

*DASM* (Differential Asymmetry (Asimmetria Differenziale))

*DWT* (Trasformata di Wavelet Discreta)

*DE* (Entropia Differenziale)

*DCAU* (Differential Count of Amplitude Units (Caudalità Differenziale))

*EMD* (Entropia campionaria)

*EEG* (Elettroencefalogramma)

*Feature Extraction* (Estrazione delle caratteristiche)

*ICA* (Indipendent Component Analysis)

*IMF* (funzioni di modalità intrinseca)

*PCA* (Principal Component Analysis)

*Pre-processing* (Pre-elaborazione)

*PSD* (Densità Spettrale di Potenza)

*RASM* (Relative Asymmetry (Asimmetria Relativa))

*SEED-IV* (Stress and Emotion in Everyday Decision-making - Interactive Version)

*STFT* (Trasformata di Fourier a breve termine)

*SVM* (Support Vector Machine)

*XBoost* (Extreme Gradient Boosting)